نگاهی بر ابزارهای کلانداده: معرفی Flume و ZooKeeper



دانشگاه فردوسی مشهد

دانشکده: علوم ریاضی

رشته: ریاضی کاربردی

گرایش: علوم داده

درس: مدلسازی و پردازش مهدادهها

استاد: دكتر جلال الدين نصيري

نویسنده: پرهام پیشرو

شماره دانشجویی: 401130917

چکیده

در این فایل مستند که برای ارائه پاورپوینت آماده شده است، اطلاعات و توضیحات لازم برای فردی که قصد توضیح این ارائه را برای دیگران دارد ولی اطلاع کافی از ارائه موجود ندارد، آورده شده است. مطالب این مستند در ۴ فصل به همراه یک مقدمه و یک پیوست تنظیم شده است. فصلهای مورد نظر به ترتیب عبارتند از: آپاچی فلوم، آپاچی زوکیپر، یک نمای کلی از اکوسیستم هدوپ و مراجع.

تعداد اسلایدهای فایل ارائه پاورپوینت برابر با ۲۰ اسلاید و تعداد اسلایدهای فایل پی دی اف منطبق بر پاورپوینت به علت تعداد زیاد و مهم بودن انیمیشنها افزایش یافته و برابر با ۳۰ اسلاید می باشد. هم چنین تعداد صفحات این فایل مستند نیز برابر با ۲۰ صفحه است.

مقدمه

اگر بخواهیم به یکی از مهمترین و پر کاربردترین مسائل حال حاضر جهان اشاره کنیم، باید از کلان داده یاد کرد. کلان داده یا همان Big Data مفهومی است که به مقدار عظیمی از داده (چه ساختاریافته باشد و چه بدون ساختار) اشاره می کند. امروزه بیشتر صنایع و شرکتهای غول با این مفهوم درگیر هستند و درباره آن صحبت می کنند. در این مفهوم چیزی که مهم است، کارهایی است که با این کلان داده می توان انجام داد. از این کلان داده می وان برای استخراج اطلاعات با ارزش برای تصمیم گیری های مهم استفاده کرد. با آنالیز درست این داده ها می توان استراتژی های حساس و دقیقی را تنظیم کرد. استراتژی هایی که واقعا بدون وجود این کلان داده ها احتمالاً تنظیمشان غیرممکن بود. [۱]

حال جهت فهمیدن تفاوت بین دادههای معمولی و کلان دادهها باید به ویژگیهای کلان داده اشاره کرد. طبق یک سری از مؤلفهها و ویژگیها می توان کلان داده را تعریف کرد. در سالهای اخیر دانشمندان و محققین ویژگیهای بسیاری را برای کلان داده در نظر گرفته اند که همگی آنها با حرف "V" شرع می شوند. شایان ذکر است که اگر در صنایع مختلف صرفاً چند مورد از موارد زیر وجود داشتند، باز هم می توان آنها را در حوزه کلان داده شمرد:

- حجم ای به اندازه مجموعه دادههای مورد نیاز برای تجزیه و تحلیل و پردازش اشاره دارد که در حال حاضر اغلب از ترابایت و پتابایت بزرگتر هستند. حجم عظیم دادهها به فناوریهای پردازش گر متمایز و متفاوتی نسبت به قابلیتهای ذخیرهسازی و پردازش سنتی نیاز دارد. به عبارت دیگر، این بدان معناست که مجموعه دادهها در کلان دادهها بسیار بزرگتر از آن هستند که بتوان با یک لپتاپ یا پردازنده رومیزی معمولی پردازش کرد. نمونهای از مجموعه دادههای با حجم بالا، تمامی تراکنشهای کارتهای اعتباری در یک روز است.
- سرعت بن به سرعت تولید دادهها اشاره دارد. دادهها با چنان سرعتی تولید می شوند که به تکنیکهای پردازش مجزا (توزیع شده) نیاز دارند. نمونهای از دادههایی که با سرعت بالا تولید می شوند پیامهای توییتر یا پستهای فیسبوک هستند.
- تنوع ی داده ها، کلان داده را واقعا بزرگ می کند. داده های بزرگ از منابع بسیار متنوعی به دست می آید و به طور کلی یکی از سه نوع است: داده های ساختار یافته، نیمه ساختار یافته و بدون ساختار. تنوع در انواع داده ها اغلب به قابلیت پردازش متمایز و الگوریتم های تخصصی نیاز دارد. نمونه ای از مجموعه داده های متنوع می تواند فایل های صوتی و تصویری دوربین مدار بسته باشد که در مکان های مختلف یک شهر تولید می شوند.

موارد فوق ۳ تا از مهمترین ویژگیهای کلان داده بودند. [۲] ابزارهای متعددی برای حوزه کلان داده در اختیار کاربران قرار دارد. از جمله آپاچی هدوپ (Apache Hadoop)، الگوریتم نگاشت کاهش (Map Reduce)، سیستم فایل توزیع شده هدوپ(Hadoop Distributed File System | HDFS)، آپاچی هایو (Apache Spark)، آپاچی هایو (Apache Pig)، آپاچی هایو (Apache Pig)، آپاچی هایو (Apache Pig)، آپاچی ماهوت (Apache Mahout)، آپاچی پیگ (Apache Pig)، آپاچی ماهوت (Apache Flume)، کافکا (Apache Flume) و آپاچی زوکیپر (Apache Flume)، و س. در ادامه به دو مورد از ابزارهای کلان داده یعنی آپاچی فلوم (Apache Flume) و آپاچی زوکیپر (Zookeeper

" Variety

^{&#}x27; Volume

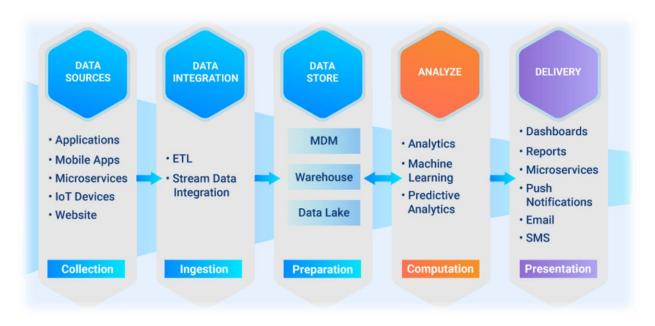
^{*} Velocity

قبل از بررسی آپاچی فلوم و آپاچی زوکیپر باید نگاهی کلی به روند کلی یک پروژه کلان داده داشته باشیم. در ۵ مرحله مختلف پروژههای کلان داده انجام میشوند:

- (۱) جمع آوری: شامل جمع آوری دادهها از برنامهها، نرمافزارهای موبایل، سرویسهای کوچک، دستگاههای مجهز به اینترنت اشیا، وبسایتها و انواع دیگر منابع داده است.
- ۲) یکپارچه سازی و انتقال: دادهها با انواع مختلف (مثلاً صوت، تصویر، متن، جدول، دادههای جریانی و ...) در این گام دریافت شده و پس از یکپارچه سازی آنها به مرحله بعد ارسال میشوند. از جمله ابزارهای کاربردی در این مرحله میتوان به کافکا و فلوم اشاره کرد.
- **۳) ذخیره سازی** : دادهها با توجه به ماهیت و کاربردشان و همچنین هدف صورت مسئله در حالتهای مختلفی از جمله انباره داده و دریاچه داده ذخیره میشوند.
- ۴) تجزیه و تحلیل: در این مرحله داده ها با ابزارهای مختلفی تجزیه و تحلیل شده و نتایج آنها در گام بعدی نشان داده خواهد شد.
- ۵) ارائه نتایج: پس از انجام تجزیه و تحلیل بر روی دادهها، باید نتایج حاصل را نشان داد که این کار با ابزارهای مختلفی از جمله داشبوردها، گزارشها، اعلانها، ایمیل، پیامک و ... انجام خواهد شد.

همه این ۵ مرحله گفته شده در شکل ۱ که در زیر آمده است، به نمایش درآمده است. به ترتیب از چپ به راست نشان دهنده مراحل مختلف می باشد.

شایان ذکر است که دو ابزاری که در این ارائه قرار است بررسی شوند، یعنی آپاچی فلوم و آپاچی زوکیپر در مراحل مختلفی قرار می گیرند. آپاچی زوکیپر نیز با توجه به وظیفه اش که مدیریت اجزای مختلف اکوسیستم هدوپ است، می تواند در گامهای مختلفی قرار گرفته باشد.



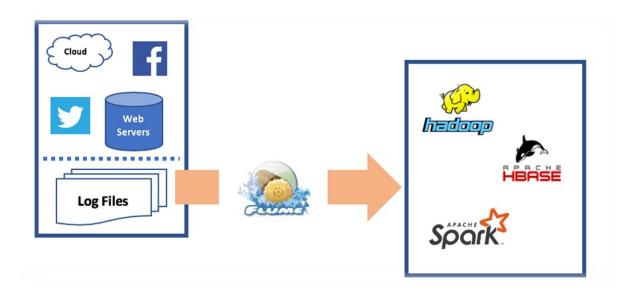
١ آپاچي فلوم

مطالب این فصل از [۴] ، [۵] و [۶] گردآوری شده است. قبل از پرداختن به بخشهای مختلف آپاچی فلوم می توان خط زمانی به بوز رسانیهای این نرمافزار را مشاهده کرد. این خط زمانی شامل نسخه نرم افزار و تاریخ ارائه آن است. خط زمانی این نرم افزار به صورت زیر می باشد:

۲۶ جولای ۲۰۱۲	١,٢,٠	•
۲ ژانویه ۲۰۱۳	1,7,1	•
۲ جولای ۲۰۱۳	1,4,0	•
۱۶ جولای ۲۰۱۴	۱,۵,۰,۱	•
۲۰ می ۲۰۱۵	١,۶,٠	•
۱۷ اکتبر ۲۰۱۶	١,٧,٠	•
۴ اکتبر ۲۰۱۷	۱,۸,۰	•
۸ ژانویه ۲۰۱۹	١,٩,٠	•
۱۶ آگوست ۲۰۲۲	1,1.,1	•
۲۴ اکتبر ۲۰۲۲	١,١١,٠	•

۱٫۱ مقدمهای بر آپاچی فلوم

همان طور که در شکل ۲ میتوان مشاهده کرد، آپاچی فلوم در واقع دادهها را از منابع داده می گیرد (که این دادهها می توانند انواع مختلفی از جمله دادههای فضای ابری، دادههای سرورهای وب، دادههای فیسبوک، دادههای توییتر و دادههای لاگ داشته باشند) و آنها را به مرحله بعدی برای پردازش (مثل Apache Spark و Apache HBASE ،Hadoop) ارسال کند. قدرت آپاچی فلوم زمانی معلوم خواهد شد که از دادههای لاگ استفاده شود، زیرا فلوم بیش تر با هدف انتقال دادههای لاگ ساخته شده است.



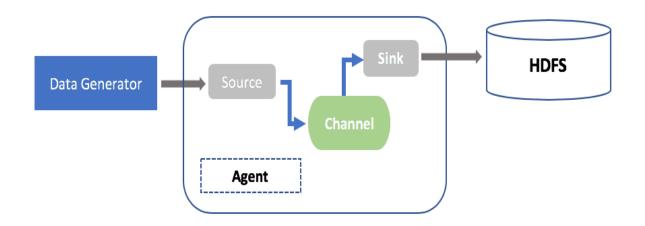
طبق تعریف رسمی خود سایت آپاچی، فلوم یک سرویس توزیع شده، قابل اعتماد و در دسترس برای جمعآوری کارآمد، تجمیع و انتقال حجم زیادی از دادههای جریانی است. پس از فهمیدن مفهوم آپاچی فلوم، بیاید روی این مورد زوم کرده و نگاه دقیق تری به آن داشته باشیم.

۲٫۱ معماری آیاچی فلوم

همانطور که در شکل ۳ میتوان مشاهده کرد، فلوم از ۳ بخش مختلف تشکیل شده است. در سمت چپ شکل تولید کننده داده قرار دارد و سمت راست نیز منابع ذخیره سازی داده. در مستطیل وسط که نشان دهنده آپاچی فلوم است، میتوان ۳ بخش مختلف آپاچی فلوم را مشاهده کرد:

- بخش اول یعنی Source وظیفه جمع آوری داده را بر عهده دارد.
- بخش دوم یعنی Channel وظیقه تجمیع داده را بر عهده دارد.
- بخش آخر یعنی Sink نیز وظیفه انتقال داده بر مرحله بعد را دارد.

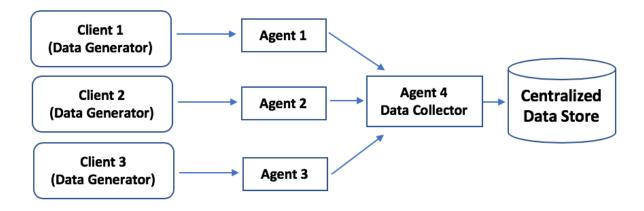
این ۳ بخش، اجزای اصلی آپاچی فلوم میباشند. معماری آپاچی فلوم که شامل Channel ،Source و Sink میباشد در ادامه نمایش داده شده است.



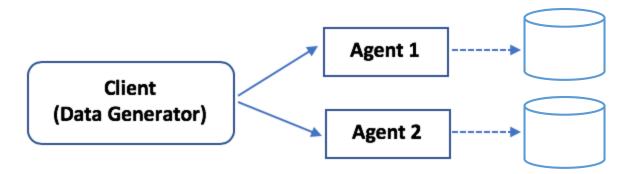
۳,۱ دو معماری مختلف

با توجه به معماری آپاچی فلوم که در بخش قبل توضیح داده شد. به دو صورت مختلف می تواند این معماری شکل بگیرد. البته می توان حالتی را در نظر گرفت که ترکیب شده از دو حالت زیر باشد (یا به عبارت دیگر حالات زیر بسط داده شده باشند)؛ ولی ساخت چنین معماری که ترکیب شده از دو حالت گذشته بوده و حالت جامع تری را شامل می شود می تواند بسیار دشوار و چالش برانگیز باشد.

اولین حالت همانطور که در شکل ۴ قابل مشاهده است، حالتی است که چندین تولید کننده ی داده (تحت عنوان مشتری) موجود باشد و قصد داشته باشیم، دادههای حاصل از این منابع تولید کننده داده را به یک منبع ذخیره سازی داده انتقال دهیم.



حالت دوم، حالتی است که در آن یک منبع تولیدکننده داده موجود باشد و قصد داشته باشیم دادههای تولید شده را به چندین منبع ذخیرهسازی انتقال دهیم. این حالت در شکل ۵ به نمایش درآمده است.



۵٫۱ چند مثال از آپاچی فلوم

در ادامه چندین مثال از آپاچی فلوم نمایش داده شده تا بهتر بتوان طرز ساز و کار معماری این نرم افزار را درک کرد. پس از مثالها نیز به محدودیتهای آپاچی فلوم پرداخته خواهد شد.

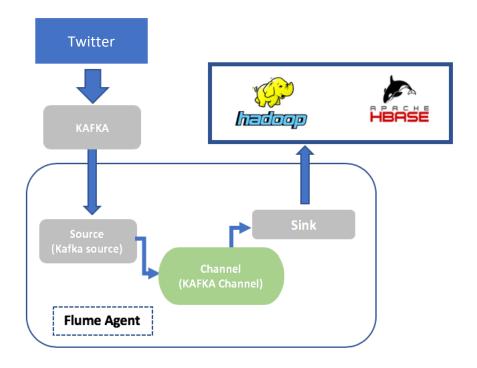
۱٫۵٫۱ انتقال دادههای جریانی لاگ از توییتر به

نحوه دریافت، جمع آوری و انتقال دادهها از شبکه توییتر به HDFS در شکل ۶ قابل مشاهده است. در واقع توییتر در ابتدا دادههای خود را با کمک Kafka به Flume انتقال میدهد. Kafka ابزاری است که در آن، هر کدام از دادهها به ترتیب همانند صف وارد مرحله بعد خواهند شد. پس از آن دادهها از طریق Source جمعآوری شده، در Channel تجمیع شده و با Apache HBASE به مرحله بعد یعنی Hadoop و یا Apache HBASE منتقل میشوند.

در شکل ۶ مستطیل وسط نشان دهنده Flume و اجزای مختلف آن می باشد. نحوه حرکت دادهها از توییتر به منابع هدوپ نیز نشان داده شده است.

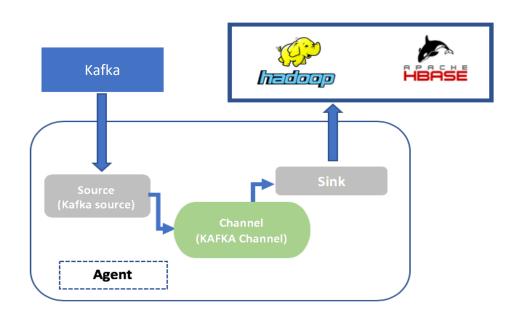
.

¹ Twitter



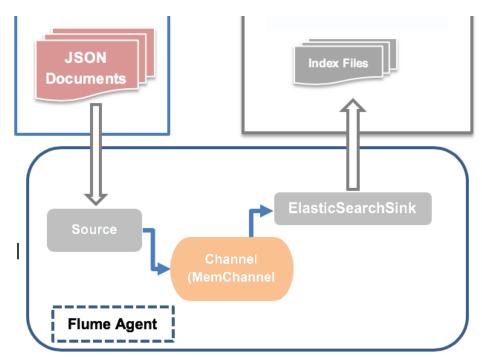
۲,۵,۱ انتقال دادههای جریانی لاگ از کافکا به

این مثال نیز همانند مثال قبل میباشد با این تفاوت که دادهها از کافکا گرفته شده اند و منبع میتواند هر چیزی باشد. شکل ۷ نشان دهنده این مسئله است.



۳,۵,۱ انتقال دادههای جریانی لاگ به الاستیک سرچ

در مثال بعد که در شکل ۸ به نمایش در آمده است، دادهها که به صورت فایلهای JSON میباشند از منابع دریافت شده و پس از قرار گرفتن در Flume که آخرین مرحله آن (یعنی مرحله انتقال دادهها) توسط الاستیک سرچ انجام میشود، دادهها به صورت فایلهای ایندکس شده به مرحله بعد منتقل میشوند.



۶٫۱ محدودیتهای آپاچی فلوم

اگر چه که فلوم دارای مزایای بسیاری است ولی دارای محدودیتها و معایبی نیز میباشد. از جمله این محدودیتها میتوان به موارد زیر اشاره کرد:

- اگر معماری را به حالتی تغییر داد که دادهها از چندین مبدا (منابع تولید کننده داده) به چندین مقصد (منابع ذخیره سازی و پردازش داده) منتقل شوند، این معماری برای مدیریت و نگهداری دادهها بسیار پیچیده و سخت خواهد بود.
 - دادههای جریانی به صورت ۱۰۰ ٪ بلادرنگ نیستند.
- آپاچی فلوم برای تعریف و از هم تشخیص دادن دادههای یکسان (دادههایی که در مجموعه داده تکرار شده اند) ضعف دارد و در این مورد ممکن است که دادهها از بین بروند.

۲ آیاچی زوکیپر

مطالب این فصل از [۷] ، [۸] ، [۹] ، [۱۰] و [۱۱] گردآوری شده است. قبل از پرداختن به بخشهای مختلف آپاچی فلوم می توان خط زمانی به بووز رسانیهای این نرمافزار را مشاهده کرد. این خط زمانی شامل نسخه نرم افزار و تاریخ ارائه آن است. خط زمانی این نرم افزار به صورت زیر می باشد:

۲۷ اکتبر ۲۰۰۸	٣,٠,٠	•
۱۴ دسامبر ۲۰۰۹	7,1,7	•
۲ آگوست ۲۰۱۲	٣,٣,۶	•
۲ آپریل ۲۰۱۹	4,4,14	•
۱۵ ژانویه ۲۰۲۱	۳,۵,۹	•
۱۳ آپریل ۲۰۲۱	٣,۶,٣	•
۱۲ می ۲۰۲۲	۳,۷,۱	•
۳۰ ژانویه ۲۰۲۳	۲,۸,۱	•

۱٫۲ چرا به آپاچی زوکیپر نیاز داریم؟

علت اصلی نیاز ما به زوکیپر هماهنگی بین سرویسهای مختلف در اکوسیستم هدوپ میباشد (یا به عبارت دیگر پیکربندی سیستمها همزمان با همگامسازی دادهها). این بدین معنی است که در صورت استفاده از اکوسیستم هدوپ، با توجه به تعدد سرویسهای موجود در آن و همچنین تزریق دادههای جدید به برنامه، هماهنگ کردن بین این سرویسهای مختلف دشوار است و پیکربندی این سرویسها در حالتی که دادهها نیز دچار مشکل نشود، سخت میباشد.به همین منظور، آپاچی زوکیپر، ۴ سرویس در اختیار ما قرار میدهد که در ادامه هر کدام نامبرده شده و در شکل ۹ نیز قابل مشاهده است:

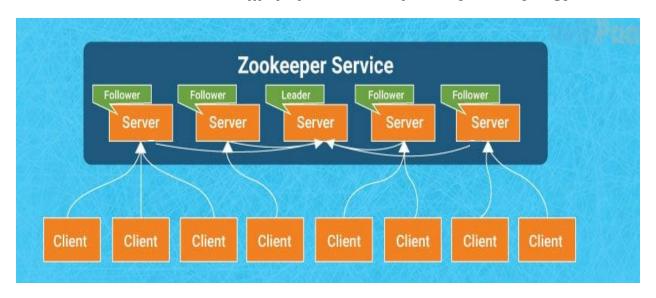
- ۱) سرویس نامگذاری
- ۲) سرویس مدیریت پیکربندی
 - ۳) سرویس همگامسازی
 - ۴) سرویس گروهها



۲٫۲ معماری آپاچی زوکیپر

همانطور که در شکل ۱۰ میتوان مشاهده کرد، این معماری متشکل از ۴ عنوان مختلف است، به نامهای سرور $^{\alpha}$ ، رهبر، $^{\gamma}$ دنبال کننده $^{\gamma}$ و مشتری $^{\wedge}$.

- سرور: نشان دهنده همان سرورهای ما است که در اختیار داریم. هر سرور باید یک نقش بگیرد یا باید رهبر باشد یا باید
 دنبال کننده باشد.
- رهبر: سروری که رهبر است وظیفه هماهنگی بین سرورهای مختلف را بر عهده دارد و با مشتریها به صورت مستقیم ارتباطی ندارد.
- **دنبال کننده:** سروری که دنبال کننده است در واقع همان درخواستهای مشتری را نشان میدهد و هر سرور توسط یک رهبر هدایت میشود.
 - مشتری: نشان دهنده همان دستگاه افرادی است که قصد دارند از سرورها استفاده کنند.



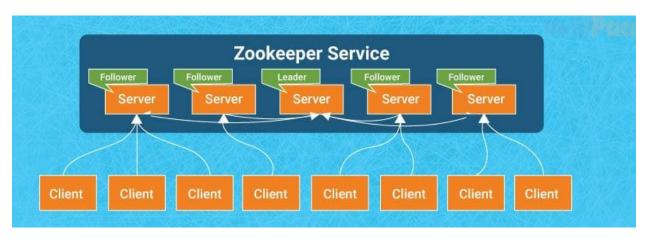
۳,۲ نحوه کار کردن آپاچی زوکیپر

حال این سرویس آپاچی زوکیپر چگونه میتواند با کمک سرورهایش که به دو دسته رهبر و دنبالکننده تقسیم شده اند، هماهنگی بین سرورها را انجام داده و همه درخواستهای مشتریان را بدون قطع شدن انجام دهد؟ نحوه عملکرد آپاچی زوکیپر در چندین مرحله متوالی نشان داده شده است.

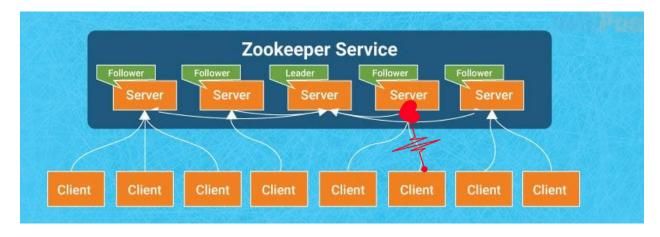
قبل از شروع سرویس زوکیپر وضعیت سرورها همانند شکل ۱۱ میباشد. همانطور که در شکل نیز پیداست هیچ ارتباطی بین سرورها و همچنین مشتریها وجود ندارد. همچنین نقش هیچیک از سرورها نیز مشخص نشده است. یعنی مشخص نشده که کدام یک از سرورها رهبر است و کدام یک دنبال کننده.



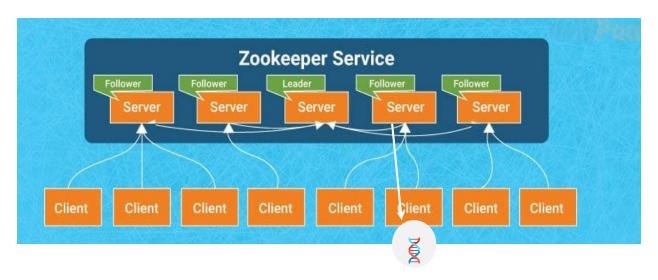
در مرحله بعد به صورت تصادفی هر کدام از مشتریها به یکی از سرورها وصل می شوند. هر سروری که به آن مشتری متصل شود، سرور دنبال کننده نام خواهد گرفت. چندین سرور نیز وظیفه هماهنگی و هدایت این سرورهای دنبال کننده را بر عهده خواهند گرفت که آنها نقش رهبر را دارند. در شکل ۱۲ این مسئله به نمایش درآمده است.



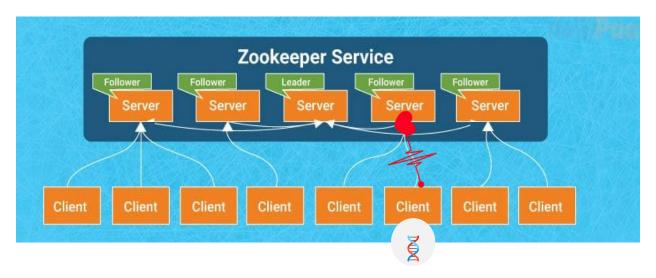
در مرحله بعدی، مشتری یک درخواست (که در اصطلاح به آن ضربان قلب می گویند) به سرور دنبال کننده ارسال می کند تا از وضعیت فعال بودن یا نبودن سرور اطمینان حاصل پیدا کند. این وضعیت در شکل ۱۳ نشان داده شده است.



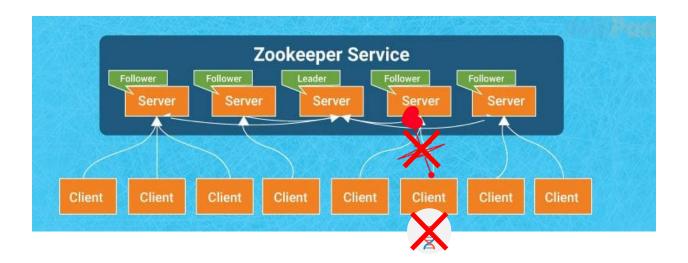
سرور نیز با اختصاص دادن یک آیدی منحصر بفرد به آن مشتری، به ضربان قلبی که از سوی مشتری ارسال شده پاسخ می دهد. هدف از این کار نشان دادن وضعیت فعال سرور است. تخصیص آیدی از سوی سرور به مشتری در شکل ۱۴ نشان داده شده است.



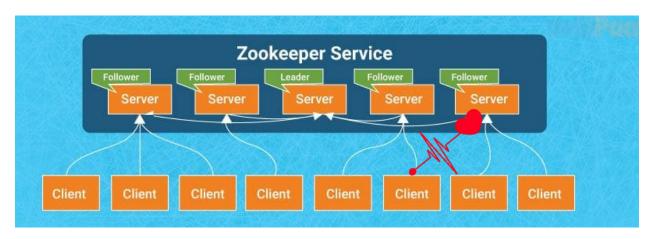
پس از ایجاد ارتباط بین سرور و مشتری، سرور شروع به کار خواهد کرد. مشتری در هر لحظه درخواستی (یا همان ضربان قلب) به سرور ارسال می کند و سرور نیز این درخواست را به مشتری جواب می دهد. این عملیات رفت و برگشت که به صورت مرتب تکرار خواهد شد، برای مطمئن شدن از ارتباط و پاسخدهی سرور می باشد. در شکل ۱۵ این ارتباط بین سرور و مشتری به وضوح نشان داده شده است.



حال اگر سرور دچار اشکال شود و یا خاموش شود و یا به هر دلیلی این ارتباط قطع شود، چه اتفاقی خواهد افتاد؟ اینجاست که قدرت آپاچی زوکیپر به نمایش در آمده و فایده استفاده از این سرویس را می توان متوجه شد. در این حالت مشتری طبق معمول یک درخواست تحت عنوان ضربان قلب به سرور می فرستد ولی سرور دیگر این ضربان قلب را پاسخ نخواهد داد و در نتیجه مشتری نیز دیگر درخواستی را به آن سرور ارسال نخواهد کرد؛ همانند شکل ۱۶. این ارتباط قطع شده و در تصویر پس از آن نشان داده می شود که چگونه آپاچی زوکیپر این مسئله را مدیریت خواهد کرد.



حال که ارتباط بین مشتری و سرور دنبال کننده قطع شده است، سرور رهبر این ارتباط را با یک سرور دنبال کننده دیگر از سر خواهد گرفت. یعنی مشتری درخواست خود را به یک سرور دیگر ارسال خواهد کرد تا وقفهای در عملیات ایجاد نشود. این عمل در شکل ۱۷ به نمایش درآمده است.



بدین صورت آپاچی زوکیپر وظیفه خود را انجام میدهد و باعث مدیریت بین اجزای مختلف اکوسیستم هدوپ و همچنین پیکربندی آنها میشود.

۴٫۲ ویژگیهای آپاچی زوکیپر

تا اینجای کار با برخی از ویژگیهای آپاچی زوکیپر آشنا شدیم. در این بخش، همانطور که در شکل ۱۸ نیز نشان داده شده است، صرفاً آنها را جمعبندی کرده و توضیح مختصری درباره هر کدام از آنها داده خواهد شد:

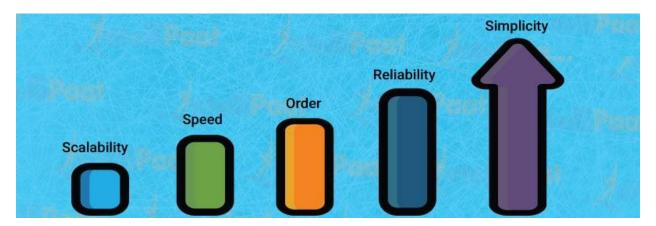
- **بهروز رسانی وضعیت گرهها:** پس از نامگذاری مشتریها و سرورها تحت عنوان گره، وضعیت هر کدام در هر لحظه بررسی شده و این وضعیت با توجه به فعال بودن یا عدم فعالیت آن گره، نمایش داده خواهد شد.
- سرویس نام گذاری: به هر گره (مشتری و سرورهای دنبال کننده و رهبر) یک نام خاص اختصاص داده خواهد شد که این نام خاص در واقع به عنوان شناسه همان گره در نظر گرفته خواهد شد. در ادامه به طور مفصل به آن پرداخته خواهد شد.

- **مدیریت خوشه:** پس از نام گذاری هر گره، که شکلی شبیه به یک درخت خواهد گرفت، هر کدام از خوشهها به طور خاص مدیریت خواهند شد.
- بهبود خطا به صورت اتوماتیک: همان طور که در بخش قبل نیز نشان داده شد، در صورت بروز هر گونه خطا در سیستم این خطا به صورت خودکار رفع خواهد شد تا وظایف تکمیل شوند.



۵,۲ فواید آپاچی زوکیپر

همان طور که در شکل ۱۹ نشان داده شده است، در این بخش به ۵ تا از مهمترین فواید آپاچی زوکیپر اشاره خواهد شد. این ۵ فایده شامل سادگی^۹، قابلیت اطمینان ۲۰ تر تیب ۲۰ سرعت ^۲و مقیاس پذیری ۲ می باشد.



۱,۵,۲ سادگی

هماهنگی بین اجزای مختلف به سادگی و با کمک فضای نام سلسله مراتبی انجام خواهد شد. این فضای نام گذاری سلسله مراتبی در بخش ۶٫۲ توضیح داده خواهد شد.

'Reliability

⁹ Simplicity

^{&#}x27;Order

^{&#}x27;Speed

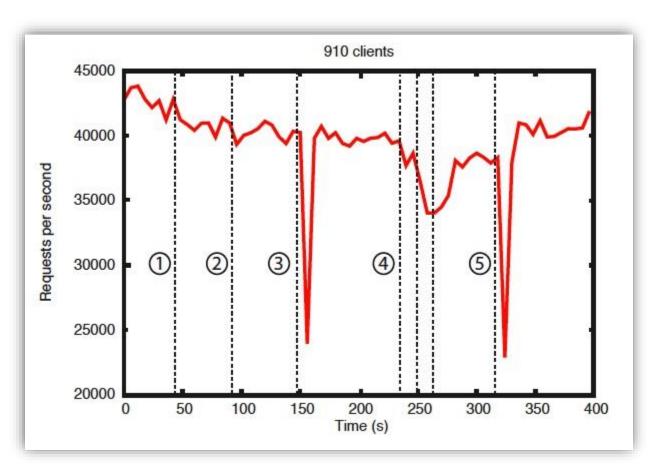
[&]quot;Scalability

٢,۵,٢ قابليت اطمينان

سیستم همچنان به کار خودش ادامه خواهد داد حتی اگر نصف گرهها از کار افتاده باشند. در واقع فقط کافیست که تعداد $\left[\frac{n}{r}\right]+1$ از گرهها فعال باشند. در رابطه با بررسی صحت این ادعا آزمایشی انجام شده است که در آن ۹۱۰ مشتری به همراه ۷ سرور وجود دارند. از این ۷ سرور ۲ سرور رهبر و ۵ سرور دنبال کننده میباشند. آزمایش انجام شده به این صورت بود که در زمانهای خاصی یک سری از این سرورها به صورت عامدانه از کار خواهند افتاد. با انجام این عمل میخواهیم نحوه کار آپاچی زوکیپر را متوجه شویم و ببینیم که آیا می توان به این سرویس اعتماد کرد یا خیر؟

طبق شکل ۲۰ می توان زمانهای ایجاد مشکل در سرورها را متوجه شد. در ۵ زمان متفاوت اغتشاشهایی به مدل وارد شده و نتایج حاصل از این اغتشاش در زیر آمده است:

- ۱) خراب کردن و بهبود بخشیدن یک سرور دنبال کننده که مشکل خاصی را ایجاد نکرده است.
- ۲) خراب کردن و بهبود بخشیدن یک سرور دنبال کننده دیگر که مشکل خاصی را ایجاد نکرده است.
 - ۳) خراب کردن و بهبود بخشیدن یک سرور رهبر که سیستم را با مشکل روبهرو کرده است.
- ۴) خراب کردن و بهبود بخشیدن دو سرور دنبال کننده که سیستم دچار مشکل جزئی شده است ولی همچنان به کار خود
 ادامه میدهد.
 - ۵) خراب کردن و بهبود بخشیدن یک سرور رهبر دیگر که سیستم را با مشکل روبهرو کرده است.



۳,۵,۲ ترتیب

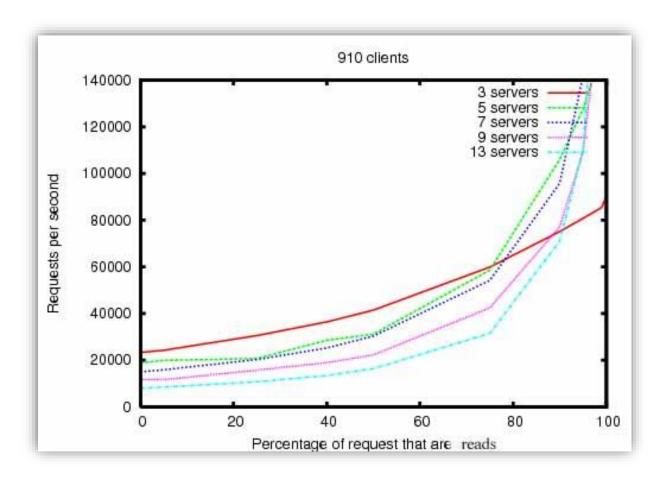
با مهر زدن به هر کدام از بهروز رسانیها با شمارهای که نشاندهنده ترتیب آن است، این عمل انجام میشود. هدف از این کار ایجاد تمایز بین گرههای مختلف و کارهایی است که هر کدام به ترتیب انجام میدهند.

۴,۵,۲ سرعت

در مواردی که عمل "خواندن" بیشتر از "نوشتن" و دیگر اعمال رایج باشد، این سیستم با یک نسبت ۱۰ به ۱ اجرا خواهد شد که این نشان دهنده سرعت فوقالعاده این سرویس است.

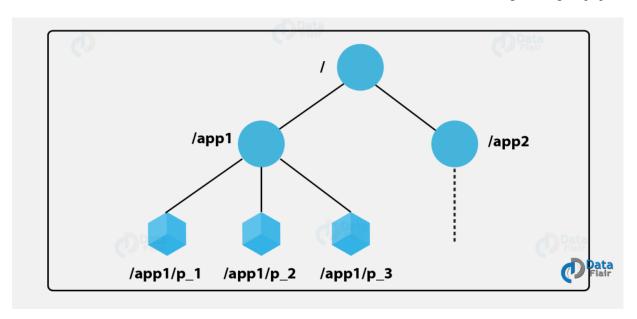
۵,۵,۲ مقیاس پذیری

عملکرد این سیستم را می توان با استقرار ماشینهای بیش تر افزایش داد. صحت این ادعا نیز طبق یک آزمایش دیگر به اثبات رسیده است. همان طور که در شکل ۲۱ می توان دید در هر مرحله از آزمایش به ترتیب ۳، ۵، ۷، ۹ و ۱۳ سرور به کار گرفته شدند و وضعیت پاسخدهی آنها به وظایف یکسان، سنجیده شده است. نتایج حاصل از این آزمایش در شکل زیر به نمایش در آمده است.



۶,۲ مدل داده و فضای سلسله مراتبی نام

از ابتدا تا به اینجای کار، دفعات زیادی از سرویس نام گذاری و فضای سلسله مراتبی آن صحبت شد؛ ولی در حقیقت منظور چیست؟ در واقع در سیستم آپاچی زوکیپر هر گره یک نام مخصوص به خود را دارد که این نام در واقع یک دنباله است به صورت مسیری از عنصرهای مختلف که با یک / از یک دیگر جدا شده اند. در واقع می توان این طور گفت که هر گره یک دنباله شامل اسامی سرورهای بالای سر خود و خود آن گره دارد. یا به عبارت دیگر هر گره با یک مسیر تعریف خواهد شد. به طور مثال نحوه تعریف این مسیر در شکل ۲۲ نشان داده شده است.

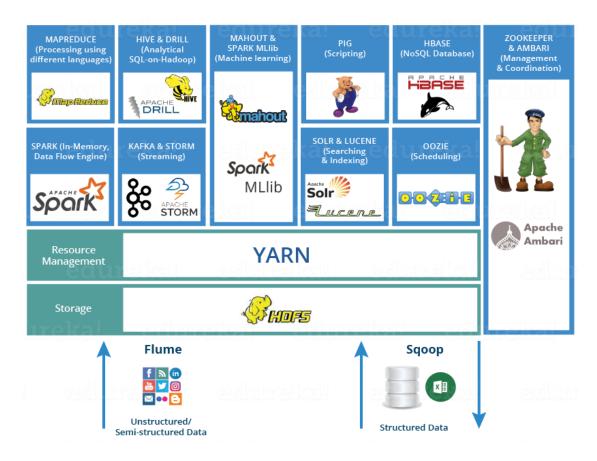


۳ یک نمای کلی از اکوسیستم هدوپ

در شکل ۲۳ می توان یک تصویر کلی از اکوسیستم هدوپ و اجزای مختلف آن داشت. همان طور که می توان دید آپاچی زوکیپر از ابتدا تا انتهای این اکوسیستم قرار دارد و آپاچی فلوم نیز وظیفه انتقال داده های بدون ساختار یا نیمه ساختار یافته را به این اکوسیستم بر عهده دارد.

اکوسیستم هدوپ بسیار گسترده میباشد به طوری که همه اجزای آن را نمیتوان در یک یا حتی دو جلسهی ۱ ساعت و ۳۰ دقیقهای بررسی کرد. لذا در این ارائه صرفاً به معرفی دو مورد از اجزای مختلف این اکوسیستم پرداخته شد و در ارائههای دیگر نیز بقیه اجزا بررسی خواهند شد.

از جمله دیگر اجزای این اکوسیستم می توان به یارن (YARN)، آپاچی اسپارک (Apache Spark)، الگوریتم نگاشت- کاهش (Map Reduce)، کافکا (Kafka)، آپاچی استورم (Apache Storm)، آپاچی هایو کاهش (Apache Drill)، آپاچی استورم (Spark MLib)، آپاچی پیگ (Apache Hive)، ماشین لرنینگ در کلانداده یا همان اسپارک اِملیب (Spark MLib)، ماهوت (Mahout)، آپاچی پیگ (Apache Pig) و دیگر موارد اشاره کرد. [۱۲]



۴ مراجع

- مقاله/کلان-داده/https://comco.computer
- [Y] https://mta.co.ir/fa/uptodateslider/uptodatedetail/2325
- [٣] https://blog.faradars.org/big-data-tools/
- [*] https://www.flume.apache.org
- [\Delta] https://logz.io/blog/apache-flume-and-data-pipelines/
- [8] https://www.tutorialspoint.com/apache flume/apache flume environment.htm
- [Y] https://www.zookeeper.apache.org
- [A] https://hopetutors.com/blog/big-data/what-is-apache-zookeeper/
- [٩] https://cloudxlab.com/blog/introduction-to-apache-zookeeper/
- [1.] https://intellipaat.com/blog/what-is-apache-zookeeper/?US
- [11] https://data-flair.training/blogs/zookeeper-architecture/
- https://www.edureka.co/community/1106/what-zookeeper-what-the-purpose-zookeeper-hadoop-ecosystem

	پيوست
لازم برای استفاده از ابزار آپاچی فلوم در پایتون	كتابخانه
pyflume	
لازم برای استفاده از ابزار آپاچی زوکیپر در پایتون	كتابخانه
kazoo	